Projet individuel – Architecture de données SmartCampus

TD 5 – Architecture polyglotte et défense

Durée : 2 heures

Architecture cible et argumentation

1. Contexte et problématique

Les précédents ateliers vous ont permis d'analyser les besoins de SmartCampus, de concevoir un modèle de données relationnel et d'étudier plusieurs technologies SQL et NoSQL.

Vous devez maintenant prendre du recul et assembler ces différents éléments dans une architecture globale.

La direction souhaite disposer d'une proposition technique permettant de répondre aux besoins actuels et futurs de SmartCampus.

Elle attend une architecture :

- Adaptée aux différents usages métier.
- Capable de supporter l'augmentation des volumes de données.
- Fiable et sécurisée.
- Facilement exploitable et maintenable.
- Compatible avec les besoins analytiques.
- Économiquement et techniquement justifiable.

Vous intervenez en tant qu'architecte data. Votre rôle consiste à proposer une architecture cible et à défendre vos choix devant un comité de décision composé de la direction technique et de la direction métier.

Problématique :

Comment concevoir une architecture de données cohérente en combinant éventuellement plusieurs technologies, tout en maîtrisant les flux, les risques, les coûts et la complexité d'exploitation ?

2. Cahier des charges complémentaire

La direction de SmartCampus vous communique les contraintes suivantes pour la future architecture.

Évolution de la plateforme :

- Le campus compte initialement 20 bâtiments.
- Il dispose de 2 000 équipements techniques.
- Environ 5 000 capteurs transmettent régulièrement des mesures.
- Le système doit pouvoir accueillir de nouveaux bâtiments et équipements.
- Les volumes de mesures sont susceptibles d'augmenter fortement.

Contraintes opérationnelles :

- Les utilisateurs doivent pouvoir consulter rapidement le dernier état des équipements.
- Les interventions doivent être enregistrées de manière fiable.
- Les mesures doivent être historisées.
- Les données ne doivent pas être perdues en cas de panne temporaire du réseau.
- Les utilisateurs doivent pouvoir consulter l'historique des événements.

Contraintes analytiques :

- La direction souhaite disposer de tableaux de bord énergétiques.
- Les consommations doivent être comparables entre bâtiments.
- Les historiques doivent permettre d'analyser les tendances.
- Les indicateurs doivent pouvoir être actualisés régulièrement.

Contraintes techniques et organisationnelles :

- La solution doit être maintenable par une équipe informatique de taille réduite.
- Les technologies retenues doivent disposer d'un écosystème suffisamment mature.
- Les coûts d'infrastructure doivent rester proportionnés aux besoins.
- Les accès doivent être sécurisés.
- Des mécanismes de sauvegarde et de restauration doivent être prévus.

3. Travail demandé

Étape 1 – Définir les composants de l'architecture cible

À partir des travaux précédents, identifiez les composants nécessaires au fonctionnement de SmartCampus.

Vous devez déterminer les responsabilités de chaque composant et les technologies éventuellement associées.

Composants à étudier :

1. Couche applicative

Elle regroupe les applications et interfaces utilisées par les différents acteurs.

Exemples :

- Interface web d'administration.

- Application de maintenance.
- Tableau de bord de supervision.
- API permettant aux applications d'accéder aux données.

2. Couche d'ingestion

Elle permet de récupérer les données provenant des capteurs et des systèmes embarqués.

Elle peut intégrer :

- Des API.
- Des connecteurs.
- Un broker de messages.
- Des mécanismes de validation des événements.
- Des files d'attente.

Vous devez déterminer si un composant de messagerie est nécessaire pour gérer les remontées fréquentes des capteurs.

3. Couche de stockage opérationnel

Elle contient les données nécessaires au fonctionnement quotidien de la plateforme.

Exemples :

- Référentiel des bâtiments.
- Référentiel des équipements.
- Gestion des interventions.
- Gestion des utilisateurs.

4. Couche de stockage spécialisé

Elle peut contenir des données organisées selon des besoins spécifiques.

Exemples :

- Configurations des équipements.
- Dernier état des capteurs.
- Historique des mesures.
- Relations entre les équipements.

Vous devez déterminer quels besoins justifient réellement l'utilisation de plusieurs moteurs.

5. Couche analytique

Elle permet de préparer les données destinées aux analyses et aux tableaux de bord.

Elle peut contenir :

- Des données historisées.
- Des données consolidées.
- Des agrégats.
- Des indicateurs métier.

6. Couche de restitution

Elle permet de mettre les informations à disposition des utilisateurs.

Exemples :

- Application de supervision.
- Tableaux de bord.
- Rapports énergétiques.
- Indicateurs de maintenance.

Questions pour vous guider :

- Quel composant est responsable de l'enregistrement des interventions ?
- Où doivent être stockées les données de référence ?
- Quel composant reçoit les mesures des capteurs ?
- Comment les données sont-elles transmises entre les composants ?
- Où doit être conservé l'historique ?
- Quelle technologie est responsable de l'état courant ?
- Comment les données sont-elles mises à disposition des outils analytiques ?

Étape 2 – Définir les responsabilités des bases de données

Pour chaque technologie retenue, vous devez définir précisément son rôle.

Attention : chaque base doit posséder une responsabilité clairement identifiée.

Complétez le tableau suivant :

Composant	Technologie envisagée	Données stockées	Usage principal
Référentiel	À définir	À définir	Gestion métier
Documents	À définir	À définir	Consultation des équipements
Cache	À définir	À définir	État courant
Historique	À définir	À définir	Mesures temporelles

Graphe	À définir	À définir	Dépendances
Analytique	À définir	À définir	Reporting

Questions de réflexion :

- Toutes les technologies étudiées doivent-elles nécessairement être retenues ?
- Peut-on gérer plusieurs besoins avec un seul moteur ?
- Quelle technologie constitue la source de référence des informations ?
- Comment éviter de stocker inutilement les mêmes informations dans plusieurs bases ?
- Quel est le coût supplémentaire induit par chaque technologie ?

Vous devez pouvoir expliquer pourquoi certaines technologies sont retenues et pourquoi d'autres ne le sont pas.

Étape 3 – Prévoir les mécanismes de synchronisation et de gestion des erreurs

Dans une architecture polyglotte, plusieurs technologies peuvent conserver différentes représentations d'une même information.

Il est donc indispensable de définir comment les données sont synchronisées.

Exemple :

Une nouvelle mesure est enregistrée dans la base historique, mais la mise à jour du dernier état du capteur échoue.

L'application possède alors :

- Une mesure historique correctement enregistrée.
- Un état courant qui n'est plus à jour.

Vous devez déterminer comment détecter et corriger cette situation.

Les mécanismes à étudier :

1. Synchronisation

Définir comment les données circulent entre les différents moteurs.

Exemples :

- Événements.
- API.

- Files de messages.
- Traitements périodiques.
- Réplication.

2. Idempotence

Une opération est idempotente lorsqu'elle peut être exécutée plusieurs fois sans produire plusieurs effets indésirables.

Exemple : recevoir deux fois la même mesure ne doit pas entraîner son enregistrement deux fois si le métier exige l'unicité de cet événement.

3. Gestion des erreurs

Prévoir les comportements en cas de :

- Perte de connexion.
- Indisponibilité d'une base.
- Erreur de format.
- Donnée invalide.
- Échec de synchronisation.
- Retard de traitement.

4. Reprise sur incident

Prévoir les mécanismes permettant de reprendre les traitements après une interruption.

Exemples :

- Files d'attente persistantes.
- Mécanismes de rejeu.
- Journalisation des événements.
- Files de messages en erreur (Dead Letter Queue).
- Réconciliation périodique entre les systèmes.

5. Cohérence des données

Déterminer quelle base fait autorité pour chaque information.

Exemple :

- PostgreSQL constitue la source de référence pour le référentiel des équipements.
- Redis conserve une représentation temporaire de leur état courant.
- Le stockage historique conserve les mesures originales.

Question importante :

Si une information est présente dans plusieurs systèmes, lequel doit être considéré comme la source de vérité ?

Étape 4 – Intégrer la sécurité et la sauvegarde

Votre architecture doit intégrer les mécanismes nécessaires pour protéger les données et garantir la continuité de service.

Sécurité :

Définissez les mécanismes nécessaires pour :

- Authentifier les utilisateurs et les équipements.
- Contrôler les droits d'accès.
- Séparer les rôles métier et techniques.
- Sécuriser les échanges entre composants.
- Chiffrer les données sensibles.
- Journaliser les opérations importantes.

Exemple SmartCampus :

Un technicien peut consulter les équipements et modifier les informations relatives à ses interventions.

En revanche, il ne doit pas nécessairement pouvoir modifier les référentiels ou accéder aux paramètres d'administration.

Sauvegarde :

Déterminez :

- Quelles données doivent être sauvegardées.
- À quelle fréquence.
- Où les sauvegardes doivent être stockées.
- Combien de temps elles doivent être conservées.
- Comment restaurer les données après une panne.

Vous devez également proposer des objectifs de continuité de service :

- RPO : perte de données maximale acceptable.
- RTO : durée maximale de rétablissement.

Exemple d'hypothèse :

- RPO de 15 minutes pour les données opérationnelles.
- RTO de 2 heures pour le rétablissement de la plateforme.

Justifiez les niveaux de protection retenus en fonction de la criticité des données.

Étape 5 – Intégrer la couche analytique

La direction souhaite suivre les performances énergétiques et techniques du campus.

Vous devez définir comment les données opérationnelles seront exploitées à des fins analytiques.

Indicateurs attendus :

- Consommation énergétique par bâtiment.
- Consommation moyenne par zone.
- Nombre d'incidents par équipement.
- Taux de disponibilité.
- Temps moyen de résolution des interventions.
- Évolution des consommations dans le temps.

Travail demandé :

1. Identifiez les données sources nécessaires.
2. Définissez comment elles seront extraites.
3. Déterminez si les transformations seront réalisées avant ou après le stockage analytique.
4. Identifiez les agrégations nécessaires.
5. Définissez la fréquence d'actualisation.
6. Précisez comment garantir la qualité des indicateurs.

Question de réflexion :

Pourquoi est-il préférable de séparer les traitements analytiques des opérations transactionnelles dans certains contextes ?

Vous pouvez représenter une chaîne analytique comprenant :

- Sources opérationnelles.
- Collecte et extraction.
- Transformation.
- Stockage analytique.
- Outil de Business Intelligence.

Étape 6 – Construire le diagramme d'architecture cible

Vous devez maintenant assembler tous les composants étudiés dans un diagramme global.

Votre représentation doit permettre de comprendre rapidement :

- Les différentes couches de l'architecture.
- Les technologies utilisées.
- Les responsabilités des composants.
- Les flux de données.
- Les mécanismes de synchronisation.
- Les relations entre les systèmes opérationnels et analytiques.

Conseils de représentation :

- Regroupez les composants par grandes couches fonctionnelles.
- Utilisez des flèches pour représenter les flux.
- Indiquez le sens de circulation des données.
- Différenciez les flux opérationnels et analytiques.
- Identifiez les sources de vérité.
- Ajoutez les mécanismes de sécurité et de sauvegarde.

Vous pouvez utiliser un outil de diagramme comme diagrams.net (Draw.io), Lucidchart ou Mermaid.

4. Préparer la recommandation exécutive

Vous devez rédiger une recommandation d'une page destinée à la direction de SmartCampus.

Ce document doit permettre à un décideur de comprendre votre proposition sans avoir besoin de lire l'ensemble des détails techniques.

Votre recommandation doit comporter cinq parties.

1. Contexte et besoin

Présentez brièvement les enjeux de SmartCampus et les contraintes principales.

2. Architecture recommandée

Présentez les technologies retenues et leur rôle respectif.

3. Justification des choix

Expliquez pourquoi cette architecture répond aux besoins identifiés.

4. Risques et limites

Présentez les principaux risques :

- Complexité d'exploitation.
- Synchronisation des données.
- Coûts d'infrastructure.
- Compétences nécessaires.
- Dépendance technologique.

5. Recommandation finale

Indiquez pourquoi la solution proposée constitue le meilleur compromis entre performances, coûts, évolutivité et maintenabilité.

5. Livrables attendus

Dossier

- Présentation des composants et de leurs responsabilités.
- Mécanismes de synchronisation et de gestion des erreurs.
- Stratégie de sécurité et de sauvegarde.
- Description de la couche analytique.
- Recommandation exécutive d'une page.

Critères de réussite :

L'architecture doit être cohérente avec les besoins métier, techniquement réalisable et proportionnée aux contraintes de SmartCampus.

Les étudiants doivent être capables de justifier chaque technologie et de défendre les compromis réalisés.